

# Cours d'analyse de données en géographie

## Niveau Master 1 - GEANDO

### Séance 3. Les paramètres statistiques élémentaires

Maxime Forriez<sup>1,a</sup>

<sup>1</sup> Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,  
<sup>a</sup>maxime.forriez@sorbonne-universite.fr

20 septembre 2025

## 1 Questions de cours

Les réponses comptent pour 10 % de la note finale du parcours « débutants ».

1. Quel caractère est le plus général : le caractère quantitatif ou le caractère qualitatif ? Justifier pourquoi.
2. Que sont les caractères quantitatifs discrets et caractères quantitatifs continus ? Pourquoi les distinguer ?
3. **Paramètres de position**
  - Pourquoi existe-t-il plusieurs types de moyenne ?
  - Pourquoi calculer une médiane ?
  - Quand est-il possible de calculer un mode ?
4. **Paramètres de concentration**
  - Quel est l'intérêt de la médiane et de l'indice de C. Gini ?
5. **Paramètres de dispersion**
  - Pourquoi calculer une variance à la place de l'écart à la moyenne ? Pourquoi la remplacer par l'écart type ?
  - Pourquoi calculer l'étendue ?
  - À quoi sert-il de créer un quantile ? Quel(s) est (sont) le(s) quantile(s) le(s) plus utilisé(s) ?
  - Pourquoi construire une boîte de dispersion ? Comment l'interpréter ?
6. **Paramètres de forme**
  - Quelle différence faites-vous entre les moments centrés et les moments absolus ? Pourquoi les utiliser ?
  - Pourquoi vérifier la symétrie d'une distribution et comment faire ?

## 2 Mise en œuvre avec Python

La sous-partie « Bonus » vous permet d’obtenir des points supplémentaires.

### 2.1 Objectifs

- Découvrir les méthodes de Pandas permettant de calculer les paramètres d’une série statistique
- Tracer une boîte de dispersion

### 2.2 Manipulations

Le fichier obtenu compte pour 10 % de la note finale du parcours « débutants ».

1. Dans le dossier `src`, créer un dossier `data` et y introduire le fichier `resultats-elections-presidentielles-2022-1er-tour.csv` disponible dans la Seance-03 du GitHub
2. Dans le dossier `src`, introduire le fichier `main.py` de la séance disponible dans la Seance-03 du GitHub
3. Ouvrir le fichier `main.py` dans votre éditeur de code (Notepad++ ou VS Code)
4. Utiliser l’instruction `with` pour ouvrir le fichier C.S.V. avec la méthode `read_csv(...)` de la bibliothèque Pandas
5. En reprenant le code précédemment créé dans la séance 2, sélectionner les colonnes contenant des caractères quantitatifs ? Calculer sous la forme d’une liste :
  - les moyennes de chaque colonne avec la bonne méthode de Pandas ;
  - les médianes de chaque colonne avec la bonne méthode de Pandas ;
  - les modes de chaque colonne avec la bonne méthode de Pandas ;
  - l’écart type de chaque colonne avec la bonne méthode de Pandas ;
  - l’écart absolu à la moyenne de chaque colonne avec la bonne méthode de Pandas ;
  - l’étendue de chaque colonne.

**N.B. 1.** Utiliser la méthode de la valeur absolue `abs()` disponible dans Numpy

**N.B. 2.** Utiliser les méthodes `min()` et `max()` disponibles dans Pandas

En utilisant la méthode `round()` de Pandas, arrondir tous les paramètres à deux décimaux.

6. Afficher la liste des paramètres sur le terminal
7. Calculer la distance interquartile et interdécile de chaque colonne quantitative avec la méthode `quantile()` dans Pandas ?
8. À l’aide de Matplotlib et d’une boucle, faire des boîtes à moustache de chaque colonne quantitative. Stocker les résultats dans un dossier `img`.

9. Dans le dossier `src`, introduire le dossier `data` le fichier `island-index.csv` disponible dans la Seance-03 du GitHub
10. Sélectionner la colonne « Surface (km<sup>2</sup>) » et écrire un algorithme pour catégoriser et dénombrer le nombre d'îles ayant une surface comprise :
  - entre 0 et 10 km<sup>2</sup> ou  $]0, 10]$  ;
  - entre 10 et 25 km<sup>2</sup> ou  $]10, 25]$  ;
  - entre 25 et 50 km<sup>2</sup> ou  $]25, 50]$  ;
  - entre 50 et 100 km<sup>2</sup> ou  $]50, 100]$  ;
  - entre 100 et 2 500 km<sup>2</sup> ou  $]100, 2500]$  ;
  - entre 2 500 et 5 000 km<sup>2</sup> ou  $]2500, 5000]$  ;
  - entre 5 000 et 10 000 km<sup>2</sup> ou  $]5000, 10000]$  ;
  - supérieur ou égal 10 000 km<sup>2</sup> ou  $]10000, +\infty[$ .

Vous concevrez un organigramme pour expliquer votre solution. L'objectif de cette dernière question est d'apprendre à catégoriser des variables quantitatives.

## 2.3 Bonus

Sans remarque pour vous aider (conditions réelles), sortir les listes calculées avec la bonne méthode `Pandas` au format `C.S.V.` et `Excel`. N'oubliez pas de titrer les colonnes et les lignes de vos sorties si nécessaire.